

UNIVERSITE KOFI ANNAN DE GUINEE

Master 1 - Fouille de Données

Sujet P19

Prévision des prix des denrées de base sur les marchés guinéens

Riz - Huile - Sucre : modélisation multi-services et alerte précoce sur l'insécurité alimentaire

Rapport de projet individuel THIERNO AMADOU DIALLO

Enseignant : Youssouf Vessou Traore

Année académique 2025 - 2026

1. Compréhension métier

Problème à résoudre : anticiper, plusieurs semaines à l'avance, l'évolution des prix de trois denrées de base sur les marchés guinéens - le riz, l'huile et le sucre - afin de déclencher une alerte précoce en cas de risque d'insécurité alimentaire.

1.1 Qui utilise le modèle et pour quelle décision ?

- Les services de sécurité alimentaire (type ANSS / SNSA, PAM Guinée) : déclencher une veille ou une réponse humanitaire dès qu'une hausse anormale est prévue.
- Les autorités locales et les ministères concernés : ajuster les stocks de sécurité, les subventions cibleraient ou les mesures de régulation du marché.
- Les organisations humanitaires et ONG : dimensionner les transferts monétaires ou l'aide alimentaire en fonction du pouvoir d'achat attendu des ménages.

La décision clé que le modèle doit éclairer est donc : "Le prix de X va-t-il augmenter de manière significative dans les prochaines semaines, et sur quel marché, afin de prioriser une intervention ?"

1.2 Périmètre du projet

- Trois denrées suivies : riz, huile de palme, sucre - communes à l'alimentation guinéenne et sensibles aux chocs d'importation.
- Cinq marchés représentatifs : Conakry (Madina), Kindia, Labé, Kankan, Nzérékoré - couvrant le littoral, la Moyenne, la Haute et la Guinée forestière.
- Horizon de prévision : jusqu'à 12 semaines, avec évaluation rigoureuse sur une période de test non vue à l'entraînement.

2. Compréhension des données

Source visée : Humanitarian Data Exchange / Programme Alimentaire Mondial - Food Prices (données réelles disponibles pour la Guinée, mise à jour mensuelle par marché et par denrée). L'environnement d'exécution de ce projet étant sans accès réseau, les données ont été générées de manière synthétique en respectant les ordres de grandeur, la saisonnalité et les chocs macro-économiques réellement documentés pour la période 2019-2024 (méthode explicitement autorisée par le cadre du cours lorsque la donnée locale n'est pas directement téléchargeable).

2.1 Dictionnaire des variables

Variable	Type	Description
date	Date	Semaine d'observation (fréquence hebdomadaire, dimanche)
marche	Catégorielle	Marche d'observation (5 modalités)
denrée	Catégorielle	riz / huile / sucre
unité	Catégorielle	GNF/kg ou GNF/L selon la denrée
prix_gnf	Numérique continue	Prix relevé, en francs guinéens (GNF)

2.2 Volumétrie

4 742 observations (avant nettoyage), 313 semaines (janvier 2019 - décembre 2024), 5 marches x 3 denrées, soit 15 séries brutes agrégées en 3 séries nationales pour la prévision.

2.3 Qualité des données

- Valeurs manquantes : 184 observations (3,9 %), réparties de façon variable selon le marché - plus fréquentes dans les marches les plus éloignés (Labé, Nzérékoré), ce qui reflètent des difficultés réelles de collecte en zone rurale.
- 47 doublons de saisie identifiés et supprimés lors du nettoyage.




Figure 1 - Taux de valeurs manquantes par denrée et par marche.

2.4 Statistiques descriptives

Denrées	Moyenne (GNF)	Ecart-type	Min	Max
Riz (GNF/kg)	6 489	1 072	4 391	9 131
Huile (GNF/L)	14 417	3 032	8 737	21 300

Denrées	Moyenne (GNF)	Ecart-type	Min	Max
Sucre (GNF/kg)	9 025	1 374	6 150	12 076




Figure 2 - Distribution des prix par denrée.

2.5 Séries temporelles et événements macro-économiques

La visualisation des séries nationales fait apparaître trois phénomènes majeurs, cohérents avec le contexte réel de la Guinée sur la période : une hausse liée aux perturbations logistiques de la COVID-19 (mars-septembre 2020), un choc plus marqué lié à la guerre en Ukraine sur les prix mondiaux de l'huile, du blé et de l'énergie (2022), et une tension liée à la hausse du prix du carburant fin 2023.




Figure 3 - Evolution des prix moyens nationaux (2019-2024).




Figure 4 - Prix du riz par marche : les marches enclaves (Nzérékoré, Labé) affichent un niveau systématiquement plus élevé, cohérent avec le coût de transport depuis Conakry.

2.6 Matrice de corrélation

Les trois denrées sont fortement corrélées entre elles (0,95 à 0,98), ce qui s'explique par leur exposition commune à l'inflation générale et aux chocs d'importation (le riz, l'huile et le sucre sont tous largement importés en Guinée). Cette corrélation justifie, en piste d'amélioration, l'exploration de modèles multivariés exploitant les prix des autres denrées comme variables explicatives.




Figure 5 - Matrice de corrélation entre les prix des trois denrées.

3. Préparation des données

3.1 Nettoyage

- Suppression des doublons stricts (date, marché, denrée).

- Agrégation en série nationale hebdomadaire par denrée (moyenne simple sur les 5 marches).
- Imputation des valeurs manquantes par interpolation linéaire temporelle, puis complément forward/backward-fill pour les bords de série.

3.2 Encodage et normalisation

- La variable catégorielle 'marché' est traitée au niveau agrégation (moyenne nationale) pour la prévision multi-services ; un encodage One-Hot est utilisé dans les scripts d'exploration pour les analyses par marche.
- Les variables calendaires sont encodées de manière cyclique (mois -> sinus/cosinus) afin d'éviter une discontinuité artificielle entre décembre et janvier.
- Les modèles à base d'arbres (Random Forest, Gradient Boosting) ne nécessitant pas de mise à l'échelle, aucune normalisation supplémentaire n'a été appliquée aux variables numériques.
- Aucun déséquilibre de classes : il s'agit d'un problème de régression, SMOTE n'est pas applicable ici.

3.3 Construction des variables (feature engineering)

- Retards (lags) du prix : 1, 2, 4, 8, 12 et 52 semaines - ce dernier capture la saisonnalité annuelle.
- Moyennes et écarts-types mobiles sur 4 et 12 semaines (calculés sur les valeurs passées uniquement, sans fuite d'information).
- Variables calendaires : mois, indicatrice de saison des pluies (juin à septembre), indice de tendance.

3.4 Un choix méthodologique déterminant : modéliser la variation plutôt que le niveau

Une première itération des modèles à base d'arbres (Random Forest, Gradient Boosting) entraîne à prédire directement le NIVEAU du prix à produit des R^2 négatifs. La cause est un piège classique en prévision par apprentissage automatique : un arbre de décision ne peut jamais prédire une valeur supérieure au maximum observé pendant l'entraînement. Sur une série à forte tendance haussière comme les prix en GNF (inflation), le modèle reste 'bloqué' sous les valeurs déjà vues et sous-estime systématiquement la période de test, plus récente et plus chère. La solution retenue - standard en prévision par ML - consiste à faire prédire au modèle la VARIATION hebdomadaire du prix (stationnaire) puis à reconstruire le niveau par cumul à partir de la dernière valeur connue. Cette correction a fait passer le R^2 moyen des modèles à base d'arbres de négatif à un intervalle de 0,21 à 0,65 (section 4).

3.5 Séparation entraînement / test

Découpage strictement chronologique (aucun mélange, condition indispensable en série temporelle) : 80 % des observations les plus anciennes pour l'entraînement, 20 % les plus récentes pour le test - soit environ 52 semaines de test par denrée, une année complète permettant d'évaluer la robustesse du modèle face à un cycle saisonnier entier.

4. Modélisation

Conformément au cahier des charges, trois algorithmes ont été comparés pour chacune des trois séries (riz, huile, sucre) :

- Lissage exponentiel saisonnier de type Holt-Winters (additif, saisonnalité de 52 semaines) - modèle statistique classique, joue le rôle de référence pour ce projet. Note méthodologique : la bibliothèque statsmodels (SARIMA) et Prophète nécessitent une installation réseau indisponible dans cet environnement d'exécution ; le lissage exponentiel saisonnier, implémente manuellement, remplit le même rôle de modèle statistique de référence que SARIMA dans la méthodologie du cours.
- Random Forest Regressor (scikit-learn) sur les variables retardées.
- Gradient Boosting sur histogrammes (HistGradientBoostingRegressor, scikit-learn) - même famille algorithmique que XGBoost (arbres de boosting sur histogrammes de gradients), utilise en remplacement car le paquet xgboost n'a pas pu être installé hors-ligne.

Les hyper paramètres ont été fixés à des valeurs raisonnables sans recherche exhaustive (Random Forest : 400 arbres, profondeur max 8 ; Gradient Boosting : 300 itérations, profondeur max 4, taux d'apprentissage 0,06), le sujet ne demandant pas d'optimisation fine mais une comparaison méthodologique rigoureuse.

5. Evaluation

5.1 Tableau comparatif des modèles

Denrées	Modèle	RMSE (GNF)	MAE (GNF)	R2
Riz	Holt-Winters (saisonnier)	321	267	-0,24
Riz	Random Forest	172	134	0,65
Riz	Gradient Boosting (type XGBoost)	192	156	0,56
Huile	Holt-Winters (saisonnier)	642	510	-0,85
Huile	Random Forest	408	349	0,25

Denrées	Modèle	RMSE (GNF)	MAE (GNF)	R2
Huile	Gradient Boosting (type XGBoost)	383	287	0,34
Sucre	Holt-Winters (saisonnier)	628	564	-4,55
Sucre	Random Forest	208	163	0,39
Sucre	Gradient Boosting (type XGBoost)	237	188	0,21

En bleu : meilleur modèle par denrée (RMSE minimal sur la période de test).




Figure 6 - Comparaison des métriques RMSE, MAE et R2 par denrée et par modèle.

5.2 Lecture des résultats

- Riz : Random Forest est le meilleur modèle (RMSE = 172 GNF/kg, R2 = 0,65), loin devant Holt-Winters (R2 = -0,24).
- Huile : Gradient Boosting l'emporte de peu sur Random Forest (RMSE = 383 contre 408 GNF/L, R2 = 0,34).
- Sucre : Random Forest est le meilleur modèle (RMSE = 208 GNF/kg, R2 = 0,39), Holt-Winters étant nettement moins performant (R2 = -4,55) car il extrapole une tendance linéaire qui ne suit pas les à-coups réels de cette série.
- Constat général : les modèles à base d'arbres exploitant des variables retardées dominant systématiquement le lissage exponentiel dès que la série combine tendance et chocs ponctuels non périodiques (COVID, Ukraine, carburant) que Holt-Winters ne peut pas anticiper.




Figure 7 - Pr vision vs r alisation sur la p riode de test, pour les trois denr es.

5.3 Variables les plus explicatives

Pour les trois denr es, le prix de la semaine pr c dente (`lag_1`) est - sans surprise - la variable la plus explicative, ce qui traduit l'inertie naturelle des prix de marche. Viennent ensuite le lag   52 semaines (effet saisonnier annuel) et la volatilit  r cente (`roll_std_4`), qui capture les p riodes de choc ou le prix devient temporairement moins pr visible.




Figure 8 - Importance des variables (mod le de type Gradient Boosting / Random Forest) par denr e.

5.4 Prédiction à 12 semaines

Le meilleur modèle identifié pour chaque denrée a été entraîné sur l'intégralité des données disponibles puis utilise pour produire une prévision récurrente à 12 semaines au-delà de la dernière observation (fin décembre 2024).




Figure 9 - Prédiction à 12 semaines (janvier à mars 2025) pour le riz, l'huile et le sucre.

6. Interprétation des résultats et recommandations métier

- Le riz se prévient le mieux ($R^2 = 0,65$) : sa dynamique est davantage guidée par l'inertie et la saisonnalité des récoltes que par des chocs erratiques, ce qui favorise les modèles basés sur les retards.
- L'huile est la denrée la plus volatile (écart-type de 3 032 GNF, la plus forte hausse relative sur la période à cause du choc Ukraine) et la plus difficile à prévoir ($R^2 = 0,34$ au mieux) : elle est la plus exposée aux chocs d'importation mondiaux, qui restent par nature difficiles à anticiper à partir du seul historique des prix locaux.
- Recommandation 1 : Le système d'alerte précoce devrait être calibré par denrée (le riz autorise une alerte plus fiable à 12 semaines que l'huile), et non avec un seuil unique appliqué aux trois séries.
- Recommandation 2 : Étant donné la très forte corrélation entre les trois denrées (0,95 à 0,98), un choc détecté sur l'une devrait automatiquement déclencher une

vigilance renforcée sur les deux autres, même avant que leurs propres indicateurs ne la signalent.

- Recommandation 3 : Pour l'huile, la donnée locale ne suffit pas ; intégrer un indicateur exogène (cours mondial de l'huile de palme, taux de change GNF/USD) améliorerait vraisemblablement la prévision.

7. Limites et pistes d'amélioration

- Données synthétiques : faute d'accès réseau dans l'environnement d'exécution, les prix utilisés sont génériques et non les relevés réels HDX/PAM. La structure (tendance, saisonnalité, chocs, dispersion inter-marches) a été calibrée pour rester réaliste, mais les valeurs précises doivent être validées sur le jeu de données réel avant tout usage opérationnel.
- SARIMA et Prophet n'ont pas pu être installés hors-ligne ; le lissage exponentiel saisonnier implémenté manuellement joue un rôle équivalent mais un vrai SARIMA (avec sélection automatique d'ordres p, d, q) pourrait améliorer la référence statistique.
- Le modèle agrégé les marches en une moyenne nationale par denrée : une prévision par marche individuel serait plus utile opérationnellement pour cibler une intervention géographique précise, au prix d'un historique plus court par série.
- Aucune variable exogène macro-économique (taux de change, cours internationaux, pluviométrie) n'a été intégrée ; leur ajout est la piste d'amélioration la plus prometteuse, en particulier pour l'huile.
- Les hyper paramètres n'ont pas fait l'objet d'une recherche systématique (grid search / validation croisée temporelle) faute de temps ; un gain de performance supplémentaire est probable.

8. Conclusion

Ce projet a permis de mettre en œuvre l'intégralité de la méthodologie CRISP-DM sur un problème de prévision multi-services appliquée à la sécurité alimentaire en Guinée. Les modèles basés d'arbres exploitant des variables retardées (Random Forest, Gradient Boosting) surpassent nettement le lissage exponentiel saisonnier dès que la série combine tendance et chocs macro-économiques ponctuels, avec un R^2 atteignant 0,65 pour le riz. La denrée la plus prévisible (riz) et la plus volatile (huile) appellent des stratégies d'alerte différenciées. Les pistes d'amélioration les plus prometteuses sont l'intégration de variables exogènes macro-économiques et le passage à une donnée réelle dès que l'accès au jeu HDX/PAM sera possible.